

数据仓库与大数据工程 笔记本虚拟机搭建 Hadoop 集群操作文档

网络科学与智能系统研究所 2018年1月



修订记录

版本	修订		修订日	
号	状态	简要说明修订内容和范围		修订人
V1.0	A	完成 MySQL,zookeeper,Kafka 三部分	2018.1.30	宋超
V1.1	M	修改 SSH 章节的 bug	2018.1.30	宋超
V1.2	A	完成所有的 Hadoop 集群的安装说明	2018.1.31	宋超
V1.3	A	添加了封面、目录、页眉	2018.1.31	宋超
V1.4	A	新增了第二块网卡的配置方式(3.1到3.2.3)	2018.1.31	宋超
V1.5	A	修改 hadoop 安装过程的配置文件内容,增加 HDFS 的初始化,	2018.2.5	曹仲、
V 1.5	A	修改 hive 的配置文件,增加 spark 安装过程的描述	2010.2.3	宋超
V1.6	A	增加了架构图与引言 2018.2.26		宋超
V1.7	A	增加了对于虚拟机网络配置的解释	2018.3.5	宋超
V1.8	M	对 ZooKeeper 以及 Kafka 配置代码中的一些问题进行了修改		纪宇泽
V1.9	M	修改 HBase 的环境变量设置,	2018.3.9	王贝贝
V 1.9 W		修改 Storm 配置文件内容	2016.3.9	工火火
V1.91	M	修改了网卡配置的内容 2018.3.12		宋超
V1.92	M	修改了新建 hadoop 用户的内容	修改了新建 hadoop 用户的内容 2018.3.12	
V1.93	M	修改了错别字	2018.3.14	宋超
V1.94	M	修改了改 hosts 的描述	2018.3.14	宋超
V1.95	M	修改了 Hive 的启动条件	2018.3.15	宋超
V1.96	A	增加了 3.2.5 检查虚拟机间能否正常通信的内容	2018.3.16	宋超
V2.0	A	增加了各组件的测试内容以及 web 界面的进入方法	2018.3.17	宋超
V2.01	M	修复了同步 hbase 工作目录的小 bug	2018.3.17	宋超
V2.02	M	增加了使 hive 用户可以在 cluster2 上登陆 MySQL 的命令	2018.3.19	宋超
V2.03	M	修复了小 bug	2018.3.27	宋超
V2.1	M	增加 Kafka 的新配置	2018.3.29	宋超

注:修订记录在体系文件发布后换版时使用,修订状态栏填写: A—增加, M—修改, D—删除



目录

1.	概述	1
2.	服务列表	2
	搭建步骤	4
	3.1 安装虚拟机	4
	3.2 准备工作	6
	3.2.1 关闭防火墙和 Selinux	6
	3.2.2 安装软件	6
	3.2.3 检查网卡是否开机自启	6
	3.2.4 修改 hosts	8
	3.2.5 检查网络是否正常	8
	3.2.6 新建 hadoop 用户	9
	3.2.7 生成 ssh 密钥并分发	10
	3.2.8 安装 NTP 服务	10
	3.3 安装 MySQL	11
	3.3.1 安装	
	3.3.2 测试	13
	3.4 安装 JDK	
	3.4.1 安装	13
	3.4.2 测试	14
	3.5 安装 ZooKeeper	14
	3.6 安装 Kafka	17
	3.6.1 安装	17
	3.6.2 测试	19
	3.6.3 可能遇到的问题	20
	3.7 安装 Hadoop	20
	3.7.1 安装	20
	3.7.2 测试	25
	3.8 安装 HBase	29
	3.8.1 安装	
	3.8.2 测试	32
	3.8.3 可能遇到的问题	
	3.9 安装 Hive	33
	3.9.1 安装	33
	3.9.2 测试	36
	3.10 安装 Scala	37
	3.11 安装 Spark	37
	3.11.1 安装	
	3.11.2 测试	39
	3.12 安装 Storm	40



1. 概述

《数据仓库与大数据工程》实验一需要学生在笔记本上搭建 Hadoop 集群,本文档对笔记本上创建虚拟机搭建 Hadoop 集群的步骤进行了说明。包含所有需要安装的软件与服务的版本,安装路径,安装方法等。

主要流程为:安装虚拟机管理程序,创建三台虚拟服务器,在三台虚拟服务器上搭建以 Hadoop 集群为核心的大数据平台。

1



2. 服务列表

实验一要求学生搭建的大数据平台以 Hadoop 为核心,HDFS、MySQL、HBase 组成了存储系统,通过 Kafka 实时接入数据,使用 Storm 对数据进行实时分析,Map/Reduce 和 Spark 负责离线数据分析。Zookeeper 负责为分布式应用程序协调服务。

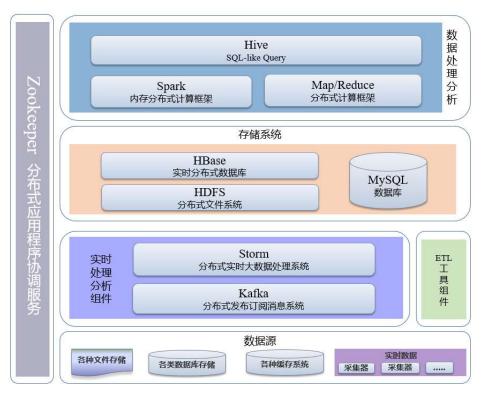


图 2-1 大数据平台架构图

用于搭建笔记本集群的虚拟机工具为 Oracle VM VirtualBox 5.1.26,使用其他工具也可用。 Hadoop 大数据平台所需工具、软件包、版本及安装目录见表 2-1.

表 2-1 Hadoop 大数据平台所需的软件包

软件包名	软件名称	版本	安装目录
jdk-7u80-linux-x64.tar.gz	java 软件开发工具	1.7.80	/usr/local/jdk1.7.0_80
	包		
mysql-5.6.37-linux-glibc2.12-	MySQL	5.6.37	/usr/local/mysql
x86_64.tar.gz			
zookeeper-3.4.6.tar.gz	Zookeeper	3.4.6	/usr/local/zookeeper-3.4.6
kafka_2.10-0.8.2.1.tgz	Kafka	2.100.8.2.1	/usr/local/kafka_2.100.8.2.1



数据仓库与大数据工程笔记本虚拟机搭建 Hadoop 集群操作文档

	1	I .	
hadoop-2.6.5.tar.gz	Hadoop	2.6.5	/usr/local/hadoop-2.6.5
hbase-1.2.6-bin.tar.gz	HBase	1.2.6	/usr/local/hbase-1.2.6
apache-hive-1.1.0-bin.tar.gz	Hive	1.1.0	/usr/local/apache-hive-1.1.0-bin
mysql-connector-java-5.1.43-bin.jar	MySQL JDBC 驱动	5.1.43	
scala-2.10.6.tgz	Scala	2.10.6	/usr/local/scala-2.10.6
spark-1.6.3-bin-hadoop2.6.tgz	Spark	1.6.3	/usr/local/spark-1.6.3-bin-
			hadoop2.6
apache-storm-1.1.1.tar.gz	Storm	1.1.1	/usr/local/apache-storm-1.1.1

所有虚拟机上需要安装的软件与服务如表 2-2 所示。

表 2-2 虚拟机运行的服务列表

	7	
主机名	服务	
cluster1	zookeeper, Kafka, HDFS(主), YARN(主), HBase(主), Hive, Spark(主), storm(主)	
cluster2	cluster2 zookeeper, Kafka, MySQL, HDFS, YARN, HBase, Hive, Spark, storm	
cluster3	zookeeper, Kafka, HDFS, YARN, HBase, Hive, Spark, storm	

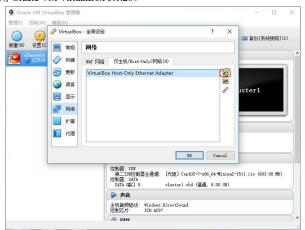


3. 搭建步骤

3.1 安装虚拟机

注意: 请关闭 360 安全卫士等软件!

下载系统镜像,可从交大知行论坛上下载,CentOS-7-x86_64-Minimal-1511.iso。 虚拟机软件使用 Oracle VM VirtualBox 5.1.26。

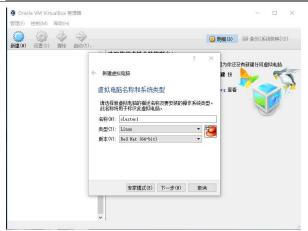


网络设置: 选择左上角的管理->全局设定->网络->NAT 网络->右侧添加网卡->双击新增的网卡->网络 CIDR: 10.0.2.0/24->选 OK->仅主机(Host-Only)网络->右侧添加网卡->双击新增的网卡->IPv4 地址: 192.168.56.1->IPv4 网络掩码: 255.255.255.0->DHCP 服务器->取消勾选"启用服务器"->OK->点 OK 保存。

这里的 NAT 网络是为了创建出一个包含三台虚拟机的局域网环境,而 Host-Only 网络是为了使笔记本能与虚拟机通信,这样在虚拟机成功安装后,就可以使用 putty 或 secureCRT 等 SSH 工具从笔记本连接到虚拟机,然后将文档中提供的配置文件内容复制粘贴进去,若不配置 Host-Only 网络,本文档所有的配置文件全部需要手动输入。

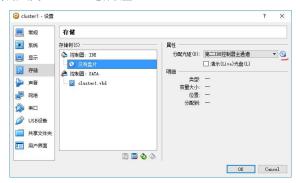
批注 [宋超1]: 2.03 更新





内存 1536M, 选择现在创建虚拟硬盘,虚拟硬盘文件类型选择 VHD(虚拟硬盘),存储分配选择动态分配 (D),大小选择 8G,然后选择创建。

右键选择创建好的虚拟机 cluster1,选择设置



存储->没有盘片->右侧的光盘图标,选择下载好的 CentOS-7-x86_64-Minimal-1511.iso,选择 OK。选择 网络->网卡 1->启用网络连接->连接方式->NAT->界面名称->选择刚才先建立的那块虚拟网卡即可->网卡 2-> 启用网络连接->连接方式->仅主机(Host-Only)网络->界面名称->选择刚才后建立的那块虚拟网卡-> OK。

双击 cluster1 进入虚拟机,选择 Install CentOS7,选择 English->continue。

DATE&TIME, Region 选择 Asia, City 选择 Shanghai, 左上角 Done。

INSTALLATION DESTINATION, 点进去后直接点左上角的 Done。

NETWORK & HOST NAME, 两张网卡右侧都选择 ON, 下面的 Host name 改为 cluster1, 左上角 Done。 选择右下角 Begin installation。

进入安装界面后选择 root password 随意。

右侧 user creation,Full name 设置为 cluster1,密码随意,不要选择 make this user administrator。

待下方进度条结束后,会有 reboot 这个选项,点击重启后,即可登陆。

再做两台这样的虚拟机分别是 cluster2 和 cluster3 即可。



3.2 准备工作

注:以下内容 "//" 后面的内容为下一行语句的注释,"#"后面的语句是使用 root 用户执行的,"\$"后面的语句是使用普通用户(3.2.5 创建的 hadoop 用户)执行的。红色是必须要注意的内容!

3.2.1 关闭防火墙和 Selinux

每台都要执行(我们安装的 centOS 最小版没有防火墙,在其他 centOS 上操作时必须要关闭防火墙)

// 关闭防火墙和 selinux

systemctl stop firewalld.service

// 禁止 firewall 开机启动

systemctl disable firewalld.service

// 开机关闭 Selinux,编辑 Selinux 配置文件

vi /etc/selinux/config

将 SELINUX 设置为 disabled

如下:

SELINUX=disabled

// 重启

reboot

// 重启机器后 root 用户查看 Selinux 状态

getenforce

3.2.2 安装软件

以下软件是安装时需要的依赖环境,安装 MySQL 时需要使用 perl 和 libaio,ntpdate 负责集群内服务器 时间,screen 用于新建后台任务。

每台都要执行

yum install perl*

yum install ntpdate

yum install libaio

yum install screen

3.2.3 检查网卡是否开机自启

每台都要执行

// 查看网卡名,看里面一个 enp0s 开头的是多少,由于我们开启了两块网卡,注意这两张都是什么名字 // 我的网卡名分别是 enp0s3 和 enp0s8,还有一个 lo,这个可以忽略不计。 # ip addr

批注 [宋超2]: 2.0 更新



使用这条命令可以查看所有网卡的信息,注意记录每张网卡的网卡名:前面序号后面的即为网卡名。 还需记录每张网卡的 ip 地址, inct 后面的就是。

```
[rootQcluster1 ~]# ip addr
1: lo: <LOOPBACK,UP,LOWER_UP> mtu 65536 qdisc noqueue state UNKNOWN
  link/loopback 00:00:00:00:00 brd 00:00:00:00:00:00
  inet 127.0.0.1/8 scope host lo
    valid_lft forever preferred_lft forever
  inet6 ::1/128 scope host
    valid_lft forever preferred_lft forever
2: enp0s3: <BROADCAST,MULTICAST,UP,LOWER_UP> mtu 1500 qdisc pfifo_fast state UP
qlen 1000
  link/ether 08:00:27:82:6f:89 brd ff:ff:ff:ff:ff
  inet 10.0.2.4/24 brd 10.0.2.255 scope global dynamic enp0s3
    valid_lft 1079sec preferred_lft 1079sec
  inet6 fe80::a00:27ff:fe82:6f89/64 scope link
    valid_lft forever preferred_lft forever
3: enp0s8: <BROADCAST,MULTICAST,UP,LOWER_UP> mtu 1500 qdisc pfifo_fast state UP
qlen 1000
    link/ether 08:00:27:8f:05:ae brd ff:ff:ff:ff:ff
[rootQcluster1 ~]# _
```

注意: 此处有两张网卡,分别是 2: enp0s3 和 3:enp0s8, 如果没有,可能是因为在安装系统的过程中,没有打开网络服务,或是网卡没有设定为开机自启。

接下来编辑网卡配置文件

编辑的第一个网卡的配置文件,应该是 ip 为 10.0.2 开头的那张网卡,网卡名为 enp0s3

// 编辑网卡配置文件

vi /etc/sysconfig/network-scripts/ifcfg-enp0s3

// 确认 ONBOOT 为 yes,这个设置为 yes 后,该网卡会开机自启,不会开机连不上网 ONBOOT=yes

接下来编辑第二张网卡的配置文件,是 enp0s8 # vi /etc/sysconfig/network-scripts/ifcfg-enp0s8

将 BOOTPROTO 设置为 none

ONBOOT=yes

新增 IPADDR=192.168.56.121 (cluster2 设置为 192.168.56.122, cluster3 为 192.168.56.123)

NETMASK=255.255.255.0

NETWORK=192.168.56.0

保存后关闭文件。

// 重启网络服务

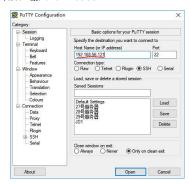
service network restart

重启成功后会出现一个绿色的 OK,失败则显示红色的 failed,若失败,则使用 reboot 重启服务器即可。重启后,就可以使用 putty 或其他 SSH 工具连接虚拟机了。



以下以 putty 为例:

在 windows 中,下载 putty,打开后,输入 192.168.56.121



然后点击右下角的 Open,即可连接到 clusterl 上。同样的,可以使用 Filezilla 传输文件。



主机为:sftp://192.168.56.121,用户名为 root,端口号不用设定,快速连接即可。

3.2.4 修改 hosts

每台都要执行

// 记录当前 ip 地址,要记录第一张网卡的 ip 地址

ip addr

// 修改 hosts

vi /etc/hosts

// 在最下面添加一下几行内容,下面的红色的 ip 地址写你用 ip addr 里面显示的第一张网卡(enp0s3)的 ip

10.0.2.6 cluster1

10.0.2.8 cluster2

10.0.2.7 cluster3

3.2.5 检查网络是否正常

// 在 cluster1 上

ping cluster2

如果出现如下界面



```
[root@cluster1 ~]# ping cluster2
PING cluster2 (10.8.2.5) 56(84) bytes of data.
64 bytes from cluster2 (10.0.2.5): icmp_seq=1 ttl=64 time=0.599 ms
64 bytes from cluster2 (10.0.2.5): icmp_seq=2 ttl=64 time=0.370 ms
64 bytes from cluster2 (10.0.2.5): icmp_seq=3 ttl=64 time=0.376 ms
64 bytes from cluster2 (10.0.2.5): icmp_seq=4 ttl=64 time=0.374 ms
64 c

--- cluster2 ping statistics ---
4 packets transmitted, 4 received, 8% packet loss, time 3009ms
rtt min/avg/max/mdev = 0.370/0.429/0.599/0.100 ms
[root@cluster1 ~]# _
```

可以看到 time=多少秒,说明可以从 cluster1 连接到 cluster2,同理,检查能否连接到 cluster3,使用 Ctrl+C 中断命令 ping。

// 检查能否连接到 cluster3

ping cluster3

如果出现如下界面

```
[root@cluster1 ~1# ping cluster2
PING cluster2 (10.0.2.7) 56(84) bytes of data.
From cluster1 (10.0.2.4) icmp_seq=1 Destination Host Unreachable
From cluster1 (10.0.2.4) icmp_seq=2 Destination Host Unreachable
From cluster1 (10.0.2.4) icmp_seq=3 Destination Host Unreachable
From cluster1 (10.0.2.4) icmp_seq=4 Destination Host Unreachable
^c
--- cluster2 ping statistics ---
5 packets transmitted, 0 received, +4 errors, 100% packet loss, time 4003ms
```

可能导致该问题的原因:

- 1. hosts 配置有误, hosts 中的 cluster2 的 ip 地址, 与 cluster2 的实际 ip 地址不同, 请返回检查 cluster2 的 ip 地址。
- 2. cluster2 处于关机状态,没有开机。

3.2.6 新建 hadoop 用户

每台都要执行

新建 hadoop 用户,这个用户专门用来维护集群,因为实际中使用 root 用户的机会很少,而且不安全。

- // 新建 hadoop 组
- # groupadd hadoop
- // 新建 hadoop 用户
- # useradd -s /bin/bash -g hadoop -d /home/hadoop -m hadoop
- // 修改 hadoop 这个用户的密码
- # passwd hadoop

批注 [宋超3]: 1.9 更新



3.2.7 生成 ssh 密钥并分发

只在 cluster1 上执行

// 生成 ssh 密钥(cluster1 上),切换到 hadoop 用户

\$ ssh-keygen -t rsa

然后一路回车

// 接下来分发密钥,请仔细观察显示的内容,会让你输入 yes

\$ ssh-copy-id cluster1

\$ ssh-copy-id cluster2

\$ ssh-copy-id cluster3

3.2.8 安装 NTP 服务

// 三台都要安装

yum install ntpdate

// cluster1 上装 ntp

yum install ntp

// cluster1 上执行以下操作

vi /etc/ntp.conf

注释掉以下 4 行,也就是在这 4 行前面加#

server 0.centos.pool.ntp.org iburst

server 1.centos.pool.ntp.org iburst

server 2.centos.pool.ntp.org iburst

server 3.centos.pool.ntp.org iburst

最下面加入

restrict default ignore

restrict 10.0.2.0 mask 255.255.255.0 nomodify notrap

server 127.127.1.0

// 重启 ntp 服务

service ntpd restart

// 设置 ntp 服务器开机自动启动

chkconfig ntpd on

// 以下为客户端的配置 (除 cluster1 外其他所有的机器,即 cluster2 和 cluster3):

设定每天00:00 向服务器同步时间,并写入日志

crontab -e

输入以下内容后保存并退出:

0 0 * * * /usr/sbin/ntpdate cluster1>> /root/ntpd.log

批注 [宋超4]: 2.0 更新



// 手动同步时间,需要在每台机器上 (除 ntp server),使用 ntpdate cluster1 同步时间 # ntpdate cluster1

3.3 安装 MySQL

3.3.1 安装

chown -R root.

```
只在 cluster2 上做以下内容,因为我们的集群中,只有 cluster2 上需要安装一个 MySQL
# yum remove mysql mysql-server mysql-libs compat-mysql51
# rm -rf /var/lib/mysql
# rm -rf /etc/my.cnf
下载 mysql-5.6.37-linux-glibc2.12-x86_64
# cp mysql-5.6.37-linux-glibc2.12-x86_64.tar.gz /usr/local/
// 解压到/usr/local/
\# tar \text{-}zxvf \text{ } mysql\text{-}5.6.37\text{-}linux\text{-}glibc2.12\text{-}x86\_64.tar.gz
// 改名为 mysql
\# mv mysql-5.6.37-linux-glibc2.12-x86_64 mysql
// 删除安装包
\#\ rm\ mysql-5.6.37\text{-}linux\text{-}glibc2.12\text{-}x86\_64.tar.gz
// 修改环境变量
# vi /etc/profile
在最下面添加
export\ MYSQL\_HOME = /usr/local/mysql
export PATH=$MYSQL_HOME/bin:$PATH
// 刷新环境变量
# source /etc/profile
// 新建 mysql 用户
                      在/etc/group 中可以看到
# groupadd mysql
# useradd -r -g mysql -s /bin/false mysql 在/etc/passwd 中可以看到
# cd /usr/local/mysql
# chown -R mysql:mysql.
# scripts/mysql_install_db --user=mysql
// 修改当前目录拥有者为 root 用户
```



- // 修改当前 data 目录拥有者为 mysql 用户
- # chown -R mysql data
- // 新建一个虚拟窗口,叫 mysql
- # screen -S mysql
- # bin/mysqld_safe --user=mysql &
- // 退出虚拟窗口
- # Ctrl+A+D
- # cd /usr/local/mysql
- // 登陆 mysql
- # bin/mysql
- // 登陆成功后退出即可
- # exit;
- // 进行 root 账户密码的修改等操作
- # bin/mysql_secure_installation

首先要求输入 root 密码,由于我们没有设置过 root 密码,括号里面说了,如果没有 root 密码就直接按回车。是否设定 root 密码,选 y,设定密码为 cluster,是否移除匿名用户: y。然后有个是否关闭 root 账户的远程 登录,选 n,删除 test 这个数据库? y,更新权限? y,然后 ok。

- # cp support-files/mysql.server /etc/init.d/mysql.server
- // 进入 mysql 虚拟窗口
- # screen -r mysql
- // 查看 mysql 的进程号
- # ps -ef \mid grep mysql

// 如果有的话就 kill 掉,保证 mysql 已经中断运行了,一般 kill 掉/usr/local/mysql/bin/mysqld 开头的即可 # kill 进程号

- // 关闭虚拟窗口
- # exit
- // 启动 mysql
- # /etc/init.d/mysql.server start -user=mysql
- # exit

还需要配置一下访问权限:

\$ mysql -u root -p

mysql> GRANT ALL PRIVILEGES ON *.* TO 'root'@'%' IDENTIFIED BY 'cluster' WITH GRANT OPTION;

批注 [宋超5]: 2.0 更新



mysql> FLUSH PRIVILEGES;

// 关闭 mysql 的指令(不需要执行) # mysqladmin -u root -p shutdown

3.3.2 测试

mysql> create database test_table;

mysql> use test_table;

mysql> create table userinfo(id int not null);

mysql> insert into userinfo values(1);

mysql> select * from userinfo;

mysql> drop database test_table;

mysql> show databases;

3.4 安装 JDK

3.4.1 安装

每台都要安装

\$ su root

cp jdk-7u80-linux-x64.tar.gz /usr/local/

tar -zxvf jdk-7u80-linux-x64.tar.gz

// 修改环境变量

vi /etc/profile

// 添加以下内容

export JAVA_HOME=/usr/local/jdk1.7.0_80/

export JRE_HOME=/usr/local/jdk1.7.0_80/jre

 $export\ CLASSPATH = .: \$JAVA_HOME/lib: \$JRE_HOME/lib: \$CLASSPATH$

 $export\ PATH = \$JAVA_HOME/bin:\$JRE_HOME/bin:\$JAVA_HOME:\$PATH$

// 复制 jdk 到其他的服务器上

 $\# \; scp \; \hbox{-r /usr/local/jdk1.7.0_80/ cluster2:/usr/local/}$

 $\#\;scp\;\text{-r}\;/usr/local/jdk1.7.0_80/\;cluster3:/usr/local/$

// cluster2 上

vi /etc/profile

// 添加以下内容

批注 [宋超6]: 2.0 更新

批注 [宋超7]: 2.0 更新



export JAVA_HOME=/usr/local/jdk1.7.0_80/

export JRE_HOME=/usr/local/jdk1.7.0_80/jre export CLASSPATH=::\$JAVA_HOME/lib:\$JRE_HOME/lib:\$CLASSPATH export PATH=\$JAVA_HOME/bin:\$JRE_HOME/bin:\$JAVA_HOME:\$PATH // cluster3 上 # vi /etc/profile // 添加以下内容 export JAVA_HOME=/usr/local/jdk1.7.0_80/ export JRE_HOME=/usr/local//jdk1.7.0_80/jre export CLASSPATH=::\$JAVA_HOME/lib:\$JRE_HOME/lib:\$CLASSPATH export PATH=\$JAVA_HOME/bin:\$JRE_HOME/bin:\$JAVA_HOME:\$PATH

3.4.2 测试

\$ java -version

可以看到 java 版本为 1.7.0_80 即为安装成功

3.5 安装 ZooKeeper

每台都要安装

// cluster1 上

将 zookeeper 解压到/usr/local 目录下,配置环境变量 # vi /etc/profile

// 添加以下内容

export ZOOKEEPER_HOME=/usr/local/zookeeper-3.4.6 export PATH=\$ZOOKEEPER_HOME/bin:\$PATH # cd /usr/local/zookeeper-3.4.6

// 在 conf 中新建 zoo.cfg 文件

vi conf/zoo.cfg

// 输入以下内容

客户端心跳时间(毫秒) tickTime=2000

允许心跳间隔的最大时间

initLimit=10

同步时限

syncLimit=5

数据存储目录

dataDir=/home/hadoop_files/hadoop_data/zookeeper

批注 [朱超8]: 2.0 更新

批注 [宋超9]: 2.0 更新



```
# 数据日志存储目录
dataLogDir=/home/hadoop_files/hadoop_logs/zookeeper/dataLog
# 端口号
clientPort=2181
# 集群节点和服务端口配置
server.1=cluster1:2888:3888
server.2=cluster2:2888:3888
server.3=cluster3:2888:3888
// 创建 zookeeper 的数据存储目录和日志存储目录
# mkdir -p /home/hadoop_files/hadoop_data/zookeeper
# mkdir -p /home/hadoop_files/hadoop_logs/zookeeper/dataLog
# mkdir -p /home/hadoop_files/hadoop_logs/zookeeper/logs
// 修改文件夹的权限
# chown -R hadoop:hadoop_files
# chown -R hadoop:hadoop/usr/local/zookeeper-3.4.6
// 在 cluster1 号服务器的 data 目录中创建一个文件 myid,输入内容为 1
// myid 应与 zoo.cfg 中的集群节点相匹配
# echo "1" >> /home/hadoop_files/hadoop_data/zookeeper/myid
// 修改 zookeeper 的日志输出路径(注意 CDH 版与原生版配置文件不同)
# vi bin/zkEnv.sh
// 将配置文件里面的以下项替换为红字的内容
if [ "x${ZOO\_LOG\_DIR}" = "x"]
then
        ZOO_LOG_DIR="/home/hadoop_files/hadoop_logs/zookeeper/logs"
fi
if [ "x${ZOO\_LOG4J\_PROP}" = "x" ]
then
         ZOO_LOG4J_PROP="INFO,ROLLINGFILE"
fi
// 修改 zookeeper 的日志配置文件
# vi conf/log4j.properties
// 修改为以下内容:
zookeeper.root.logger=INFO,ROLLINGFILE
log 4j. appender. ROLLING FILE = {\color{blue} org.} apache. log 4j. Daily Rolling File Appender {\color{blue} org.} apache. log 4j. Daily Rolling File Appender {\color{blue} org.} apache. log 4j. Daily Rolling File Appender {\color{blue} org.} apache. log 4j. Daily Rolling File {\color{blue} org.} apache. log 4j. Dai
将这个 zookeeper-3.4.6 的目录复制到其他的两个节点上
# scp -r /usr/local/zookeeper-3.4.6 cluster2:/usr/local/
```



```
# scp -r /usr/local/zookeeper-3.4.6 cluster3:/usr/local/
// 退回 hadoop 用户
# exit
// 刷新环境变量
$ source /etc/profile
// 启动 zookeeper
$ zkServer.sh start
// cluster2 上面 改环境变量,加入以下内容
export ZOOKEEPER_HOME=/usr/local/zookeeper-3.4.6
export PATH=$ZOOKEEPER_HOME/bin:$PATH
// 创建 zookeeper 的数据存储目录和日志存储目录
$ su root
# mkdir -p /home/hadoop_files/hadoop_data/zookeeper
# mkdir -p /home/hadoop_files/hadoop_logs/zookeeper/dataLog
# mkdir -p /home/hadoop_files/hadoop_logs/zookeeper/logs
// 添加 myid
{\it \# echo "2"}>> {\it /home/hadoop\_files/hadoop\_data/zookeeper/myid}
// 修改文件夹的权限
# chown -R hadoop:hadoop_files
# chown -R hadoop:hadoop /usr/local/zookeeper-3.4.6
// 退回 hadoop 用户
# exit
// 刷新环境变量
$ source /etc/profile
// 启动 zookeeper
$ zkServer.sh start
// cluster3 上面 加环境变量
# vi /etc/profile
```

export ZOOKEEPER_HOME=/usr/local/zookeeper-3.4.6 export PATH=\$ZOOKEEPER_HOME/bin:\$PATH

// 创建 zookeeper 的数据存储目录和日志存储目录 # mkdir -p /home/hadoop_files/hadoop_data/zookeeper



mkdir -p /home/hadoop_files/hadoop_logs/zookeeper/dataLog # mkdir -p /home/hadoop_files/hadoop_logs/zookeeper/logs

// 添加 myid

echo "3" >> /home/hadoop_files/hadoop_data/zookeeper/myid

// 修改文件夹的权限

chown -R hadoop:hadoop_files

chown -R hadoop:hadoop /usr/local/zookeeper-3.4.6

// 退回 hadoop 用户

exit

// 刷新环境变量

\$ source /etc/profile

// 启动 zookeeper (每台都要执行,而且三台要接连执行,都启动后再做下面的)

\$ zkServer.sh start

// 三台 zookeeper 都启动后,使用 jps 命令查看进程是否启动

jps

可以看到一个叫 QuorumPeerMain 的进程,说明 zookeeper 启动成功

// 退出 root 用户

exit

// 查看 zookeeper 状态

\$ zkServer.sh status

可以看到三台中有一个是 leader,两个是 follower

// 关闭 zookeeper 的命令 (关机前在每台上都要执行,这里不需要执行)

\$ zkServer.sh stop

3.6 安装 Kafka

3.6.1 安装

// cluster1 上

kafka_2.10-0.8.2.1 解压到/usr/local

//添加环境变量

 $export\ KAFKA_HOME = /usr/local/kafka_2.10 - 0.8.2.1$

批注 [宋超10]: 2.0 更新



export PATH=\$KAFKA_HOME/bin:\$PATH

// 修改配置文件

vi /usr/local/kafka_2.10-0.8.2.1/config/server.properties

// 修改下面3项

// 第一项: 这个值要唯一,不同的机器不能相同,cluster1 就写 1,cluster2 就写 2,cluster3 就写 3 broker.id=1

// 第二项: 修改日志路径

log.dirs=/home/hadoop_files/hadoop_logs/kafka

// 第三项: 此处要写 zookeeper 集群的 ip+端口号,<mark>逗号隔开</mark> zookeeper.connect=cluster1:2181,cluster2:2181,cluster3:2181

// 第四项:此处要写对应机器的 ip 地址!

advertised.host.name=192.168.56.121

//修改完环境变量,更新配置文件 #source /etc/profile

// 保存退出后创建 logs 文件夹

mkdir -p /home/hadoop_files/hadoop_logs/kafka

// 修改权限

chown -R hadoop:hadoop/home/hadoop_files

chown -R hadoop:hadoop/usr/local/kafka_2.10-0.8.2.1

// 复制文件夹

 $\#\;scp\;\hbox{--}r\;/usr/local/kafka_2.10\hbox{--}0.8.2.1\;cluster2\hbox{:/}usr/local/$

scp -r /usr/local/kafka_2.10-0.8.2.1 cluster3:/usr/local/

// cluster2 上

 $\#\ vi\ /usr/local/kafka_2.10\text{-}0.8.2.1/config/server.properties}$

 $broker.id \!\!=\!\!\! 2$

// cluster3 上

vi /usr/local/kafka_2.10-0.8.2.1/config/server.properties

broker.id=3

// 使用 hadoop 用户启动 kafka 集群

先启动 zookeeper 集群,然后在 kafka 集群中的每个节点使用

\$ kafka-server-start.sh /usr/local/kafka_2.10-0.8.2.1/config/server.properties & 启动完成后按回车即可 **批注 [宋超11]:** 2.1 更新



3.6.2 测试

// 创建 topic

\$ kafka-topics.sh --create --zookeeper cluster1:2181,cluster2:2181,cluster3:2181 --replication-factor 3 --partitions 1 --topic mykafka

// 查看 Topic:

\$ kafka-topics.sh --list --zookeeper cluster1:2181,cluster2:2181,cluster3:2181 此时会显示 Topic: mykafka

// 查看详细信息

\$ kafka-topics.sh --describe --zookeeper cluster1:2181,cluster2:2181,cluster3:2181

Topic:mykafka PartitionCount:1 ReplicationFactor:3Configs:

Topic: mykafka Partition: 0 Leader: 133 Replicas: 133,134,132 Isr: 134

// 发送消息(cluster1 上执行)

\$ kafka-console-producer.sh --broker-list localhost:9092 --topic mykafka

// 接收消息 (cluster2 上执行)

\$ kafka-console-consumer.sh -zookeeper cluster1:2181,cluster2:2181,cluster3:2181 --topic mykafka --from-beginning

// 在 cluster1 输入以下内容

test

mycluster test

可以在 cluster2 上看到相应的信息 按 Ctrl+C 退出

// 关闭 kafka,在每台上执行

\$ kafka-server-stop.sh

//新建虚拟窗口 kafka, 在每台上执行

\$ screen -S kafka

// 启动 kafka 集群,在每台上执行

 $\$\ kafka-server-start.sh\ /usr/local/kafka_2.10-0.8.2.1/config/server.properties$

// 退出虚拟窗口 kafka,在每台上执行

\$ Ctrl+A+D

在每台服务器上面执行 jps 可以看到 Kafka 进程在运行



// 关闭 kafka 的命令为,在每台服务器上进入虚拟窗口 kafka,然后使用 kafka-server-stop.sh 即可。

3.6.3 可能遇到的问题

- 1. 如果出现以下信息,则需要下载 slftj-nop-1.5.jar,并将其复制至 kafka 的 libs 目录下:
- SLF4J: Failed to load class "org.slf4j.impl.StaticLoggerBinder".
- SLF4J: Defaulting to no-operation (NOP) logger implementation
- SLF4J: See http://www.slf4j.org/codes.html#StaticLoggerBinder for further details.
- 2. Error: while executing topic command replication factor: 3 larger than available brokers: 1 这是因为没有将 3 台机器的 kafka 都启动。

3.7 安装 Hadoop

3.7.1 安装

Hadoop 启动的先决条件是 zookeeper 已经成功启动

// 在 cluster1 节点/usr/local/解压 hadoop 安装包

\$ su roo

tar -zxvf hadoop-2.6.5.tar.gz

// 删除安装包

rm hadoop-2.6.5.tar.gz

// 切换到存有 hadoop 配置文件的目录

cd /usr/local/hadoop-2.6.5/etc/hadoop

// 修改 hadoop-env.sh 文件

vi hadoop-env.sh

将 export JAVA_HOME=\${JAVA_HOME}替换为 export JAVA_HOME=/usr/local/jdk1.7.0_80 export HADOOP_PID_DIR=/home/hadoop_files

// 配置 mapred-env.sh

vi mapred-env.sh

export HADOOP_MAPRED_PID_DIR=/home/hadoop_files

// 配置 core-site.xml 文件

vi core-site.xml

<configuration>

<!-- 指定 hdfs 的 nameservices 名称为 mycluster,与 hdfs-site.xml 的 HA 配置相同 --> property>

<name>fs.defaultFS</name>

批注 [宋超12]: 2.0 更新



```
<value>hdfs://cluster1:9000</value>
  </property>
  <!-- 指定缓存文件存储的路径 -->
  property>
    <name>hadoop.tmp.dir</name>
    <value>/home/hadoop_files/hadoop_tmp/hadoop/data/tmp</value>
  </property>
  <!-- 配置 hdfs 文件被永久删除前保留的时间(单位:分钟),默认值为0表明垃圾回收站功能关闭 -->
  property>
    <name>fs.trash.interval</name>
    <value>1440</value>
  <!-- 指定 zookeeper 地址,配置 HA 时需要 -->
  property>
    <name>ha.zookeeper.quorum</name>
    <value>cluster1:2181,cluster2:2181,cluster3:2181
  </configuration>
// 配置 hdfs-site.xml 文件
# vi hdfs-site.xml
<configuration>
  <!-- 指定 hdfs 元数据存储的路径 -->
  property>
    <name>dfs.namenode.name.dir</name>
    <value>/home/hadoop_files/hadoop_data/hadoop/namenode</value>
  </property>
  <!-- 指定 hdfs 数据存储的路径 -->
  property>
    <name>dfs.datanode.data.dir</name>
    <value>/home/hadoop_files/hadoop_data/hadoop/datanode</value>
  </property>
  property>
    <name>dfs.secondary.http.address</name>
    <value>cluster1:50090</value>
  </property>
  <!-- 数据备份的个数 -->
  property>
```



```
<name>dfs.replication</name>
    <value>3</value>
  </property>
  <!-- 关闭权限验证 -->
  property>
    <name>dfs.permissions.enabled</name>
    <value>false</value>
  </property>
  <!-- 开启 WebHDFS 功能(基于 REST 的接口服务) -->
  property>
    <name>dfs.webhdfs.enabled</name>
    <value>true</value>
  </property>
</configuration>
// 配置 mapred-site.xml 文件
# vi mapred-site.xml
<configuration>
  <!-- 指定 MapReduce 计算框架使用 YARN -->
  property>
    <name>mapreduce.framework.name</name>
    <value>yarn</value>
  <!-- 指定 jobhistory server 的 rpc 地址 -->
  property>
    <name>mapreduce.jobhistory.address</name>
    <value>cluster1:10020</value>
  </property>
  <!-- 指定 jobhistory server 的 http 地址 -->
    <name>mapreduce.jobhistory.webapp.address</name>
    <value>cluster1:19888</value>
  </property>
</configuration>
// 配置 yarn-site.xml 文件
# vi yarn-site.xml
<configuration>
  <!-- NodeManager 上运行的附属服务,需配置成 mapreduce_shuffle 才可运行 MapReduce 程序 -->
  property>
```



删除 localhost

```
<name>yarn.nodemanager.aux-services</name>
    <value>mapreduce_shuffle</value>
  <!-- 配置 Web Application Proxy 安全代理(防止 yarn 被攻击) -->
  property>
    <name>yarn.web-proxy.address</name>
    <value>cluster2:8888</value>
  </property>
  <!-- 开启日志 -->
  property>
    <name>yarn.log-aggregation-enable</name>
    <value>true</value>
  <!-- 配置日志删除时间为7天,-1为禁用,单位为秒 -->
  property>
    <name>yarn.log-aggregation.retain-seconds</name>
    <value>604800</value>
  </property>
  <!-- 修改日志目录 -->
  property>
    <name>yarn.nodemanager.remote-app-log-dir</name>
    <value>/home/hadoop_files/hadoop_logs/yarn</value>
  </property>
  property>
   <name>yarn.resourcemanager.address</name>
    <value>cluster1:8032</value>
  </property>
  property>
    <name>yarn.resourcemanager.scheduler.address</name>
    <value>cluster1:8030</value>
  </property>
  property>
    <name>yarn.resourcemanager.resource-tracker.address</name>
    <value>cluster1:8031</value>
  </property>
</configuration>
// 配置 slaves 文件
# vi slaves
```

23



```
添加以下内容:
cluster1
cluster2
cluster3
// 创建配置文件中涉及的目录(在所有结点上)
# mkdir -p /home/hadoop_files/hadoop_data/hadoop/namenode
# mkdir -p /home/hadoop_files/hadoop_data/hadoop/datanode
# mkdir -p /home/hadoop_files/hadoop_tmp/hadoop/data/tmp
# mkdir -p /home/hadoop_files/hadoop_logs/yarn
// 修改文件夹权限 (在所有结点上)
# chown -R hadoop:hadoop /home/hadoop_files/
# chown -R hadoop:hadoop/usr/local/hadoop-2.6.5/
// 将 cluster1 的 hadoop 工作目录同步到集群其它节点
$ scp -r /usr/local/hadoop-2.6.5 cluster2:/usr/local/
$ scp -r /usr/local/hadoop-2.6.5 cluster3:/usr/local/
// 修改文件夹权限 (在所有结点上)
# chown -R hadoop:hadoop/usr/local/hadoop-2.6.5/
// 在集群各节点上修改环境变量
# vi /etc/profile
export HADOOP_HOME=/usr/local/hadoop-2.6.5
export LD_LIBRARY_PATH=$HADOOP_HOME/lib/native
export PATH=$HADOOP_HOME/bin:$HADOOP_HOME/sbin:$PATH
// 使修改的环境变量生效
$ source /etc/profile
// 启动 zookeeper 集群(分别在 cluster1, cluster2 和 cluster3 上执行)
$ zkServer.sh start
接下来开始格式化:
// 启动 journalnode (在所有 datanode 上执行, 也就是 cluster1, cluster2, cluster3)
$ hadoop-daemon.sh start journalnode
启动后使用 jps 命令可以看到 JournalNode 进程
// 格式化 HDFS(在 cluster1 上执行)
$ hdfs namenode -format
// 格式化完毕后可关闭 journalnode(在所有 datanode 上执行)
```

批注 [宋超13]: 2.0 更新

\$ hadoop-daemon.sh stop journalnode



// 启动 HDFS (cluster1 上)

\$ start-dfs.sh

// 启动后 cluster1 上使用 jps 可以看到 NameNode, DataNode, SecondaryNameNode

cluster2 和 cluster3 上可以看到 DataNode

\$ jps

// 启动 YARN (cluster1 上)

\$ start-yarn.sh

// 启动后 cluster1 上使用 jps 可以看到 NodeManager, ResourceManager

cluster2 和 cluster3 上可以看到 NodeManager

\$ jps

批注 [宋超15]: 2.0 更新

批注 [宋超14]: 2.0 更新

批注 [宋超16]: 2.0 更新

// 以下两条命令是关闭 YARN 和 HDFS 的命令,重启服务器或关机前一定要执行,否则有可能导致数据或服务损坏

// 美闭 YARN 的命令(cluster1 上)

\$ stop-yarn.sh

// 关闭 HDFS 的命令(cluster1 上)

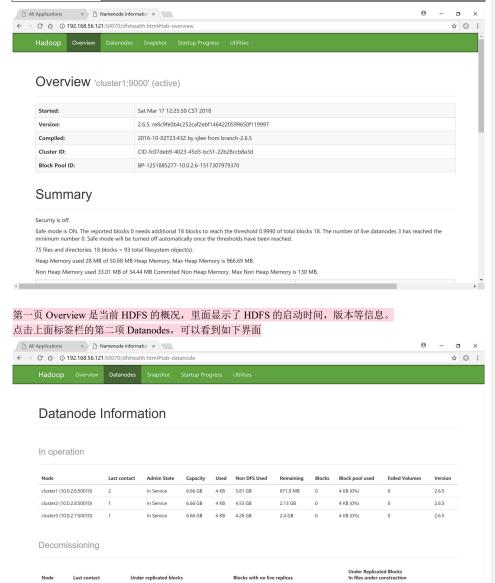
\$ stop-dfs.sh

3.7.2 测试

启动 HDFS 后,可以在浏览器中,打开 192.168.56.121:50070,可以看到 HDFS 的 web 界面



数据仓库与大数据工程笔记本虚拟机搭建 Hadoop 集群操作文档



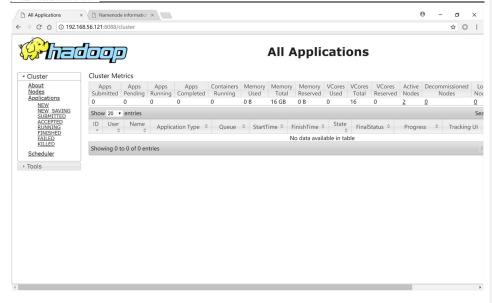
这个页面显示了当前 HDFS 中的可用节点。

Hadoop, 2016. 192.168.56.121:50070/dfshealth.html#tab-snapshot

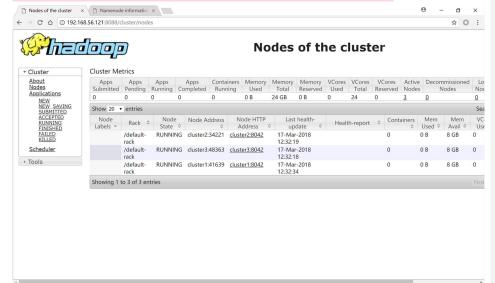
启动 YARN 后,可以通过浏览器访问 192.168.56.121:8088, 查看 YARN 的 web 界面



数据仓库与大数据工程笔记本虚拟机搭建 Hadoop 集群操作文档



该页面展示了所有提交到 YARN 上的程序,点击左侧的 Nodes 可以看到 YARN 的节点



注意,此处可以看到每个节点的可用内存 Mem Avail 为 8G,我们的虚拟机每台内存只有 1.5G,之所以出现这个问题是因为我们没有在 yam-site.xml 这个文件中对节点的可用内存进行配置,可以增加一下内容进行配置:

<!-- 配置 nodemanager 可用的资源内存 -->



property>

<name>yarn.nodemanager.resource.memory-mb</name>

<value>20480</value>

</property>

<!-- 配置 nodemanager 可用的资源 CPU -->

property>

<name>yarn.nodemanager.resource.cpu-vcores</name>

<value>24</value>

</property>

由于我们的虚拟机没有那么大的内存空间以及 CPU 资源,所以我们暂时不设置这两个参数,在后续实验中, 需要同学们设置这个参数以达到集群性能的最大化。

命令行测试:

// cluster1

// 切换至 hadoop 用户的主目录

\$ cd ~/

// 新建一个测试文件

\$ vi testfile

输入

1 2

3

// 保存退出

// 查看 HDFS 根目录的文件

\$ hdfs dfs -ls /

// 在 HDFS 的根目录创建 test 目录

\$ hdfs dfs -mkdir /test

// 如果出现了 mkdir: Cannot create directory /test. Name node is in safe mode.说明 HDFS 刚启动不久,还在安 全检查中。由于我们的笔记本性能不够强,安全检查的时间会很长,可以使用命令退出安全模式,看到 Safe mode is OFF, 再执行上面的创建目录的命令

\$ hdfs dfsadmin -safemode leave

[hadoop@cluster1 ~]\$ hdfs dfsadmin -safemode leave Safe mode is OFF

// 创建完文件夹后再次查看根目录, 查看目录是否新建成功 \$ hdfs dfs -ls /

// 将测试文件 testfile 上传至 HDFS 根目录下的 test 目录中



\$ hdfs dfs -put testfile /test

// 在 cluster2 上

// 切换至 hadoop 用户的主目录

\$ cd ~/

// 查看 HDFS 根目录

\$ hdfs dfs -ls /

// 查看 HDFS 根目录下的 test 目录,可以看到我们刚才在 cluster1 上上传的文件 testfile

\$ hdfs dfs -ls /test

// 查看 HDFS 上的/test/testfile 文件的内容

\$ hdfs dfs -cat /test/testfile

// 将 HDFS 上的/test/testfile 下载到本地

\$ hdfs dfs -get /test/testfile

// 查看本地当前目录内的内容,可以看到刚才下载的 testfile

\$ ls

批注 [宋超17]: 2.0 更新

3.8 安装 HBase

3.8.1 安装

HBase 启动的先决条件是 zookeeper 和 Hadoop 已经启动

// 切换至 root 用户

\$ su root

// 在 cluster1 节点/usr/local/解压 hbase 安装包

tar -zxvf hbase-1.2.6-bin.tar.gz

// 进入 hbase 的 conf 目录

#cd /usr/local/hbase-1.2.6/conf/

// 修改 hbase-env.sh

vi hbase-env.sh

将 JAVA_HOME, HADOOP_HOME, HBASE_LOG_DIR, HBASE_MANAGES_ZK 修改为以下内容:

记得去掉前面的#

配置 JDK 安装路径

export JAVA_HOME=/usr/local/jdk1.7.0_80

配置 Hadoop 安装路径

export HADOOP_HOME=/usr/local/hadoop-2.6.5

批注 [宋超18]: 2.0 更新



```
# 设置 HBase 的日志目录
export HBASE_LOG_DIR=/home/hadoop_files/hadoop_logs/hbase/logs
# 使用独立的 ZooKeeper 集群
export HBASE_MANAGES_ZK=false
# 设置 pid 的路径
export HBASE_PID_DIR=/home/hadoop_files
// 配置 hbase-site.xml
# vi hbase-site.xml
<configuration>
        property>
            <name>hbase.rootdir</name>
            <value>hdfs://cluster1:9000/hbase</value>
        property>
            <name>hbase.cluster.distributed</name>
            <value>true</value>
        property>
            <name>hbase.master</name>
            <value>60000</value>
        property>
            <name>hbase.tmp.dir</name>
            <value>/home/hadoop_files/hadoop_tmp/hbase/tmp</value>
        property>
            <name>hbase.zookeeper.quorum</name>
            <value>cluster1,cluster2,cluster3</value>
        </property>
        property>
            <name>hbase.zookeeper.property.dataDir</name>
            <value>/home/hadoop_files/hadoop_data/zookeeper</value>
        </property>
        property>
            <name>hbase.zookeeper.property.clientPort</name>
            <value>2181</value>
        </property>
```



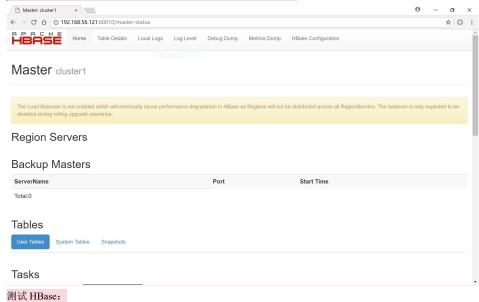
```
property>
             <name>zookeeper.session.timeout</name>
             <value>120000</value>
         </property>
        property>
             <name>hbase.regionserver.restart.on.zk.expire</name>
             <value>true</value>
        property>
             <name>hbase.master.info.port</name>
             <value>60010</value>
        </property>
</configuration>
// 配置 regionservers
# vi regionservers
删除 localhost
添加:
cluster1
cluster2
cluster3
// 删除 hbase 的 slf4j-log4j12-1.7.5.jar,解决 hbase 和 hadoop 的 LSF4J 包冲突
# cd /usr/local/hbase-1.2.6/lib
\#\ mv\ slf4j\text{-log}4j12\text{-}1.7.5.jar\ slf4j\text{-log}4j12\text{-}1.7.5.jar.bk}
// 将 hbase 工作目录同步到集群其它节点
# scp -r /usr/local/hbase-1.2.6/ cluster2:/usr/local/
# scp -r /usr/local/hbase-1.2.6/ cluster3:/usr/local/
// 创建 hbase 的缓存文件目录(所有节点)
# mkdir -p /home/hadoop_files/hadoop_tmp/hbase/tmp
// 创建 hbase 的日志文件目录(所有节点)
$ mkdir -p /home/hadoop_files/hadoop_logs/hbase/logs
// 改权限 (所有节点)
# chown -R hadoop:hadoop /usr/local/hbase-1.2.6
# chown -R hadoop:hadoop_files
```



// 在集群各节点上修改环境变量 # vi /etc/profile export HBASE_HOME=/usr/local/hbase-1.2.6 export PATH=\$HBASE_HOME/bin:\$PATH \$ source /etc/profile // 启动 HBase (cluster1 上) 先启动 zookeeper,Hadoop 的 HDFS 和 YARN,然后才能启动 HBase // 启动 HDFS (cluster1 上) \$ start-dfs.sh // 启动 YARN (cluster1 上) \$ start-yarn.sh // 启动 HBase (cluster1 上) \$ start-hbase.sh 启动后 cluster1 上使用 jps 可以看到 HMaster 和 HRegionServer cluster2 和 cluster3 上可以看到 HRegionServer // 关机前执行关闭 HBase 的命令(cluster1 上) \$ stop-hbase.sh

3.8.2 测试

用浏览器打开 192.168.56.121:60010,可以看到 HBase 的 web 界面



32



// cluster1 上

\$ hbase shell

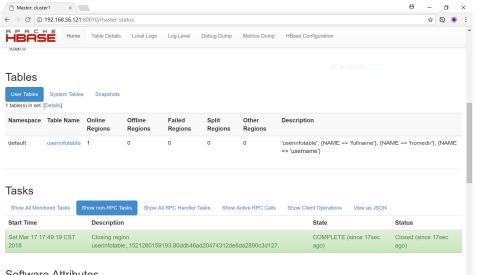
hbase> create 'userinfotable', {NAME=>'username'}, {NAME=>'fullname'}, {NAME=>'homedir'}

hbase> put 'userinfotable', 'r1', 'username', 'vcsa'

hbase> put 'userinfotable','r2','username','sasuser'

hbase> scan 'userinfotable'

可以看到刚才插入的信息,在 web 界面也可以看到刚才建立的表。



Software Attributes

删除刚才建立的表:

hbase> disable 'userinfotable'

hbase> drop 'userinfotable'

hbase> exit

3.8.3 可能遇到的问题

1. HRegionServer 闪退, 在 cluster1 上使用 start-hbase.sh 启动后, 用 jps 查看进程, 可以看到 HRegionServer, 过一会儿再看就消失了。

解决方法: 有可能是时间不同步导致的问题, 检查三台服务器的时间是否还同步。

3.9 安装 Hive

3.9.1 安装

以下内容除在 MySQL 中创建 hive 用户和创建 hive 数据库只用操作一次,其他操作需要在每个 Hadoop 结

批注 [宋超19]: 2.0 更新



```
点上都执行一次。
注: hive 能启动的先决条件是 MySQL 已经安装并配置完成,而且 HDFS 也要启动之后才能运行 hive
# cp apache-hive-1.1.0-bin.tar.gz /usr/local
# cd /usr/local
# tar -zxvf ./apache-hive-1.1.0-bin.tar.gz
# vi /etc/profile
// 在下面加上两行:
export HIVE HOME=/usr/local/apache-hive-1.1.0-bin
export PATH=$HIVE_HOME/bin:$HIVE_HOME/conf:$PATH
// root 用户登陆 MySQL
# mysql -u root -p
// 创建用户 hive,密码 hive
mysql> GRANT USAGE ON *.* TO 'hive'@'%' IDENTIFIED BY 'hive' WITH GRANT OPTION;
// 创建数据库 hive
mysql> create database hive;
// 允许任意 ip 以 hive 登陆数据库
mysql> grant all on hive.* to hive@'%' identified by 'hive';
mysql> grant all on hive.* to hive@'localhost' identified by 'hive';
mysql> grant all on hive.* to hive@'cluster2' identified by 'hive';
// 刷新权限
mysql> flush privileges;
// 退出
mysql> exit;
// 验证 hive 用户,密码 hive
# mysql -u hive -p
// 查看当前的数据库
mysql> show databases;
若看到下面有 hive 这个库,则说明创建成功
Database
| information_schema
2 rows in set (0.00 sec)
// 退出 mysql
mysql> exit;
// 修改 hive-site.xml
# cp apache-hive-1.1.0-bin/conf/hive-default.xml.template apache-hive-1.1.0-bin/conf/hive-site.xml
```

批注 [宋超20]: 2.02 更新

vi apache-hive-1.1.0-bin/conf/hive-site.xml



property>

</property>

<name>hive.exec.local.scratchdir</name>

<value>/home/hadoop_files/hadoop_tmp/hive/iotmp</value> <description>Local scratch space for Hive jobs</description>

```
数据仓库与大数据工程笔记本虚拟机搭建 Hadoop 集群操作文档
找到以下 property 项, value 值修改成如下, 其他的在 hive-site.xml 中出现, 但是下文没出现的就不需要更
改了:
property>
   <name>javax.jdo.option.ConnectionURL </name>
   <value>jdbc:mysql://cluster2:3306/hive</value>
</property>
property>
   <name>javax.jdo.option.ConnectionDriverName </name>
   <value>com.mysql.jdbc.Driver </value>
property>
   <name>javax.jdo.option.ConnectionPassword </name>
   <value>hive</value>
property>
   <name>hive.hwi.listen.port</name>
   <value>9999 </value>
   <description>This is the port the Hive Web Interface will listen on</descript ion>
</property>
property>
  <name>datanucleus.autoCreateSchema</name>
   <value>true</value>
</property>
property>
   <name>datanucleus.fixedDatastore</name>
   <value>false</value>
</property>
  property>
    <name>javax.jdo.option.ConnectionUserName</name>
    <value>hive</value>
    <description>Username to use against metastore database</description>
  </property>
```

批注 [c21]: 与原文件相同



```
property>
    <name>hive.downloaded.resources.dir</name>
    <value>/home/hadoop_files/hadoop_tmp/hive/iotmp</value>
    <description>Temporary local directory for added resources in the remote file system.</description>
  property>
    <name>hive.querylog.location</name>
    <value>/home/hadoop_files/hadoop_logs/hive/querylog</value>
    <description>Location of Hive run time structured log file</description>
  </property>
// 拷贝 mysql-connector-java-5.1.43-bin.jar 到 hive 的 lib 下面
# cp mysql-connector-java-5.1.43-bin.jar /usr/local/apache-hive-1.1.0-bin/lib/
// 把 jline-2.12.jar 拷贝到 hadoop 相应的目录下,替代 jline-0.9.94.jar, 否则启动会报错
# cp /usr/local/apache-hive-1.1.0-bin/lib/jline-2.12.jar /usr/local/hadoop-2.6.5/share/hadoop/yarn/lib/
// 切换到 hadoop 目录中 share/hadoop/yarn/lib
# cd /usr/local/hadoop-2.6.5/share/hadoop/yarn/lib/
// 将 hadoop-2.6.5/share/hadoop/yarn/lib/里面的 jline-0.9.94 重命名
# mv jline-0.9.94.jar jline-0.9.94.jar.bak
// 创建 hive 临时文件夹和日志目录
# mkdir -p /home/hadoop_files/hadoop_tmp/hive/iotmp
# mkdir -p /home/hadoop_files/hadoop_logs/hive/querylog
// 改一下权限
# chown -R hadoop:hadoop /home/hadoop_files/
# chown -R hadoop:hadoop/usr/local/apache-hive-1.1.0-bin
3.9.2 测试
// 打开 hive 客户端
```

\$ hive hive> create table test_table(id int, name string); hive> insert into test_table values(1,"test"); // 换台服务器 hive> show tables; 应该可以看到刚才创建的 test_table

hive> select * from test_table;



hive> drop table test_table; hive> show tables; hive> exit;

3.10 安装 Scala

在 cluster1 上

\$ su root

mv scala-2.10.6.tgz /usr/local

tar -zxvf scala-2.10.6.tgz

vi /etc/profile

最下面加两行:

export SCALA_HOME=/usr/local/scala-2.10.6 export PATH=\$SCALA_HOME/bin:\$PATH

// 刷新环境变量

source /etc/profile

// 查看版本,验证安装是否成功

scala -version

// 复制到所有的服务器上

scp -r /usr/local/scala-2.10.6 cluster2:/usr/local/

scp -r /usr/local/scala-2.10.6 cluster3:/usr/local/

//在每一个节点上修改环境变量

#vi /etc/profile

export SCALA_HOME=/usr/local/scala-2.10.6 export PATH=\$SCALA_HOME/bin:\$PATH

// 刷新环境变量

source /etc/profile

// 修改文件夹权限(每一个节点都要操作)

chown -R hadoop:hadoop/usr/local/scala-2.10.6

3.11 安装 Spark

3.11.1 安装

(所有节点都要操作)

下载 spark-1.6.3-bin-hadoop2.6.tgz

// 解压

cp spark-1.6.3-bin-hadoop2.6.tgz /usr/local



```
# cd /usr/local/
# tar -zxvf spark-1.6.3-bin-hadoop2.6.tgz
# cd spark-1.6.3-bin-hadoop2.6
// 环境变量
# vi /etc/profile
添加以下内容:
export SPARK HOME=/usr/local/spark-1.6.3-bin-hadoop2.6
export PATH=$SPARK_HOME/bin:$PATH
主节点要再加一行(cluster1):
export PATH=$SPARK_HOME/sbin:$PATH
// 复制 conf 文件夹里面 template 一份,改名为 spark-env.sh
# cp conf/spark-env.sh.template conf/spark-env.sh
// 在 conf/spark-env.sh 最下面加入以下 7 行:
#vi conf/spark-env.sh
export JAVA_HOME=/usr/local/jdk1.7.0_80
export SCALA_HOME=/usr/local/scala-2.10.6
export SPARK_MASTER_IP=cluster1
export HADOOP_CONF_DIR=/usr/local/hadoop-2.6.5/etc/hadoop
export SPARK_DIST_CLASSPATH=$(/usr/local/hadoop-2.6.5/bin/hadoop classpath)
export SPARK_CLASSPATH=$HIVE_HOME/lib/mysql-connector-java-5.1.43-bin.jar
export SPARK_PID_DIR=/home/hadoop_files
// 在 conf 下面新建一个叫 slaves 的文件
# vi conf/slaves
添加以下几行
cluster1
cluster2
cluster3
// 将 hive 目录下 conf 文件夹中的 hive-site.xml 复制到 spark 的 conf 目录下
# cd /usr/local/
# cp apache-hive-1.1.0-bin/conf/hive-site.xml spark-1.6.3-bin-hadoop2.6/conf/
// 将 hadoop/etc/hadoop 文件中的 hdfs-site.xml 和 core-site.xml 文件复制到 spark 的 conf 目录下
# cp hadoop-2.6.5/etc/hadoop/hdfs-site.xml hadoop-2.6.5/etc/hadoop/core-site.xml spark-1.6.3-bin-hadoop2.6/conf/
// 将 conf 目录下的 spark-defaults.conf.template 复制一份,改名为 spark-default.conf
# cd spark-1.6.3-bin-hadoop2.6/conf/
# cp spark-defaults.conf.template spark-defaults.conf
# vi spark-defaults.conf
// 在最下面加上下面这一行
```



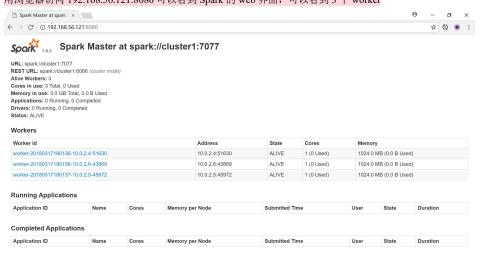
spark.files file:///usr/local/spark-1.6.3-bin-hadoop2.6/conf/hdfs-site.xml,file:///usr/local/spark-1.6.3-bin-hadoop2.6/conf/core-site.xml 保存后退出即可。

// 复制到所有的服务器上

- # scp -r /usr/local/spark-1.6.3-bin-hadoop2.6 cluster2:/usr/local/
- # scp -r /usr/local/spark-1.6.3-bin-hadoop2.6 cluster3:/usr/local/
- // 修改 spark 文件夹的权限 (每个 spark 结点)
- # chown -R hadoop:hadoop/usr/local/spark-1.6.3-bin-hadoop2.6
- // 运行 Spark (cluster1 上)
- 运行 spark 前需启动 hadoop 的 HDFS 和 YARN
- \$ start-master.sh
- \$ start-slaves.sh
- // 关闭 Spark 的命令 (cluster1 上)
- \$ stop-slaves.sh
- \$ stop-master.sh

3.11.2 测试

在 cluster1 上使用 jps 命令可以看到 Master 和 Worker, cluster2 和 3 上可以看到 Worder 用浏览器访问 192.168.56.121:8080 可以看到 Spark 的 web 界面,可以看到 3 个 worker



批注 [宋超22]: 2.0 更新

批注 [宋超23]: 2.0 更新



3.12 安装 Storm

```
storm 需要 python2.6 以上的版本
// 查看 python 版本
# python
可以在最上面一行看到 python 的版本
// 退出 python 交互式界面
>>> exit()
如果版本低于 2.6, 使用 yum install python, 安装 Python2.7
(以下都要在所有节点上操作)
将下载的 storm 解压到/usr/local 下
// 添加环境变量
# vi /etc/profile
export STORM_HOME=/usr/local/apache-storm-1.1.1
export PATH=$STORM_HOME/bin:$PATH
// 改一下权限
# chown -R hadoop:hadoop apache-storm-1.1.1
// 更改配置文件
# vi apache-storm-1.1.1/conf/storm.yaml
里面有两个要改的地方
第一个是
storm.zookeeper.servers:
    - "cluster1"
       "cluster2"
    - "cluster3"
第二个是加入一行
storm.local.dir: "/home/hadoop_files/hadoop_tmp/storm/tmp"
切记:冒号左右要有空格,否则会报错 could not found expected ':'
storm.local.dir 的最左边也要有一个空格
// 然后新建 tmp 文件夹,改权限
# mkdir -p /home/hadoop_files/hadoop_tmp/storm/tmp
# chown -R hadoop:hadoop_files
# chown -R hadoop:hadoop /usr/local/apache-storm-1.1.1
// 新建 storm-master 的虚拟窗口(cluster1)
$ screen -S storm-master
$ storm nimbus
$ Ctrl+A+D
```



// 新建 storm-supervisor 的虚拟窗口(cluster2,cluster3)

\$ screen -S storm-supervisor

\$ storm supervisor

\$ Ctrl+A+D

// 新建 storm-ui 的虚拟窗口(cluster1)

\$ screen -S storm-ui

\$ storm ui

Ctrl+A+D

// 新建 storm-logviewer 的虚拟窗口(cluster1,cluster2,cluster3)

\$ screen -S storm-logviewer

\$ storm logviewer

\$ Ctrl+A+D

使用 jps 可以看到以下进程

cluster1: nimbus, core, logviewer cluster2: Supervisor, logviewer cluster3: Supervisor, logviewer

关闭的过程就是按逆向的顺序进入虚拟窗口后,使用 Ctrl+C 退出即可。